

Содержание

1	Введение	2
2	Кратко о Cassandra	4
3	Требования к интерфейсу сервиса распределенной блоки- ровки	6
4	Обзор существующего решения	8
5	Описание алгоритмов	10
5.1	Алгоритм обязательной блокировки	10
5.2	Алгоритм мягкой блокировки	11

1 Введение

Я работаю разработчиком программного обеспечения в компании «СКБ Контур», и наша команда занимается разработкой веб-сервиса для электронной отчетности в контролирующие органы. В периоды отчетности нагрузка на сервис растет по сравнению с межотчетными периодами, пик посещений достигается за день до конца отчетности и продолжается вплоть до ее окончания. Если наш продукт станет недоступным в последний день отчетности — тысячи организаций не смогут отчитаться в регламентированный срок, что чревато большими штрафами от контролирующего органа и последующим оттоком клиентов из нашего сервиса. Поэтому сервис должен быть устойчив к высоким нагрузкам.

Отказ системы может произойти по разным причинам, например из-за сетевых неполадок или аварийного завершения работы одной из компонент. Например, если сервер, на котором запущен отвечающий за индексацию накладных сервис, перестанет отвечать на запросы, пользователи потеряют доступ к своим данным до устранения проблемы. Эту проблему можно решить с помощью запуска сервиса на нескольких машинах: в таком случае если одна из них выйдет из строя, остальные смогут продолжить обработку запросов. Также данное решение может избавить нас от проблемы с недоступностью из-за сетевых неполадок: выпадение одной реплики сервиса из сети не остановит работу системы.

По тем же причинам необходимо использовать отказоустойчивую базу данных. По «историческим» причинам в нашем сервисе используется Cassandra от Apache: наш отдел к моменту начала разработки нового сервиса имел достаточно большой опыт в использовании и администрировании этого хранилища.

При разработке многопоточных приложений часто встает задача предоставления исключительного доступа к какому-либо разделяемому ресурсу. В большинстве современных языков программирования эта задача решается на уровне синтаксиса (конструкции `lock` в C#, `synchronized` в Java), но только в рамках одного приложения на одной машине. В нашем же случае

мы имеем дело с распределенной системой, где нескольким компонентам может потребоваться доступ к одному и тому же ресурсу. Отсюда возникает задача распределенной блокировки — необходим механизм, позволяющий решать проблему исключительного доступа к ресурсу из разных приложений.

Существует множество готовых решений данной задачи, одним из самых распространенных является Apache ZooKeeper. Однако этот инструмент обладает очень высоким порогом входа: более-менее удобный и надежный клиент для ZooKeeper есть только для Java (на котором он, собственно, и реализован), а реализация своей обертки — очень трудоемкая задача. Более того, внедрение любого стороннего решения в проект связано с массой проблем, отнимающих достаточно большое количество времени. Исследование, настройка, разворачивание и администрирование — на все это уйдет не один день даже достаточно опытного разработчика, если речь идет о новом решении, ранее не применявшемся в проекте.

В магистерской работе 2012 года Федора Фоминых задача о распределенной блокировке всплывает как подзадача при построении распределенной очереди на Cassandra. Однако в ходе использования предложенного алгоритма была отмечена достаточно важная проблема — проседание производительности в случае попытки взятия одной и той же блокировки достаточно большим количеством потоков.

Была поставлена цель — предложить и реализовать алгоритм, не имеющий проблемы со снижением производительности при любом количестве потоков. Цель была достигнута, на данный момент решение находится на стадии внедрения в проект.

2 Кратко о Cassandra

Apache Cassandra — распределенная система управления базами данных, относящаяся к классу NoSQL. За счет отказа от реляционности и транзакционности в NoSQL системах достигаются возможности хорошей горизонтальной масштабируемости и репликации. Это направление в компьютерных науках сейчас находится в стадии активного развития, и практически у каждой крупной IT-компании есть своя NoSQL база данных. Cassandra изначально была разработкой Facebook, однако в 2009 году было решено отдать проект фонду Apache Software.

В первом приближении на Cassandra можно смотреть как на следующие сущности (в порядке вложенности):

1. Кластер — множество серверов, на которых хранится множество баз данных;
2. Пространство ключей — база данных, множество таблиц;
3. Семейство колонок — таблица, множество элементов;
4. Колонка — ячейка, хранящая в себе конкретную запись.

Колонка содержит в себе следующую информацию:

1. Имя строки, в которой лежит ячейка;
2. Имя колонки, в которой лежит ячейка;
3. Набор байтов с хранимой информацией;
4. Время создания ячейки;
5. Время жизни ячейки.

Фактически семейство колонок — разреженная таблица, в которой каждая строка содержит множество ячеек, упорядоченное по имени колонки в

лексикографическом порядке. Порядок колонок в строке — важная особенность хранения данных, она является ключевой для предлагаемого алгоритма.

3 Требования к интерфейсу сервиса распределенной блокировки

Сформулируем требования к интерфейсу сервиса распределенной блокировки. Фактически необходимо реализовать две стратегии блокировки:

- Обязательная блокировка — подразумевает, что блокировка будет взята в любом случае: поток в любом случае дождется освобождения нужного ресурса и обязательно возьмет блокировку;
- Мягкая блокировка — подразумевает, что блокировка может быть и не взята: поток попытается взять блокировку, но если ресурс уже занят другим потоком, он продолжит свое выполнение.

Разница достаточно проста и прозрачна — первая стратегия применяется в случае когда оба потока обязательно должны совершить свое действие (например, вывести сообщение на консоль или в лог), вторая же применяется если нам достаточно чтобы хотя бы один поток совершил свое действие (например, взял конкретную запись из некоторого хранилища и обработал ее).

Опишем данные требования на языке C#:

Листинг 1: Описание интерфейса

```
public interface IRemoteLockCreator
{
    IRemoteLock GetLock(string lockId); // обязательная блокировка
    bool TryGetLock(string lockId, out IRemoteLock remoteLock); // мягкая блокировка
}

public interface IRemoteLock : IDisposable
{
    public string ThreadId { get; }
    public string LockId { get; }
}
```

Здесь `lockId` — строковый идентификатор ресурса, доступ к которому необходимо получить. Метод `Dispose` в реализациях интерфейса `IRemoteLock` должен освобождать блокировку, в таком случае пользоваться сервисом блокировок будет достаточно удобно с помощью конструкции `using`:

Листинг 2: Использование конструкции using

```
...  
using(remoteLockCreator.GetLock(lockId))  
{  
    // действия в блокировке  
}
```

4 Обзор существующего решения

Рассмотрим алгоритм, описанный в [ссылка].

Заведем в Cassandra 2 таблицы: основную и теневую. В качестве основы для реализаций стратегий блокировок предлагается алгоритм, который пытается взять блокировку и возвращает в качестве результата одно из трех состояний:

- Success — поток успешно взял блокировку;
- AnotherThreadIsOwner — другой поток уже владеет блокировкой;
- ConcurrentAttempt — поток не смог взять блокировку, так как другой поток попытался сделать это одновременно с ним.

Сам алгоритм выглядит следующим образом:

Листинг 3: Алгоритм `Cassandra.TryLock(lockId, threadId)`

```
1. Взять ячейки из основной таблицы из строки lockId
2. Если ячейка одна:
3.     Если columnKey = threadId:
4.         Вернуть Success
5.     Иначе:
6.         Вернуть AnotherThreadIsOwner
7. Добавить ячейку в теневую таблицу
8. Взять ячейки из теневой таблицы
9. Если ячейка в теневой таблице одна
10.    Если нет ячеек в основной таблице
11.        Добавить ячейку в основную таблицу
12.    Удалить ячейку из теневой таблицы
13.    Вернуть Success
14. Удалить ячейку из теневой таблицы
15. Вернуть ConcurrentAttempt
```

С использованием этого алгоритма достаточно просто реализовать, например, стратегию обязательной блокировки:

Листинг 4: Алгоритм `Cassandra.GetLock(lockId, threadId)`

```
1. Присвоить attempt = 1
2. Вызвать Cassandra.TryLock(lockId, threadId)
3. Если Success:
4.     Закончить
5. Если AnotherThreadIsOwner
6.     Подождать случайный промежуток времени от 0 до 1000 мс
```


7. Перейти к 2
 8. Если ConcurrentAttempt:
 9. Подождать случайный промежуток времени от 0 до 50*attempt мс
 10. Присвоить attempt = attempt + 1
 11. Перейти к 2
-

По факту потоки будут бороться друг с другом за право захвата блокировки, не пытаясь договориться друг с другом. Теоретически при большом количестве потоков может сложиться такая ситуация, что потоки могут долгое время пытаться оказаться одни в теневой таблице, то есть время взятия блокировки хотя бы одним потоком становится непредсказуемым. Еще один недостаток этого алгоритма менее очевидный. Представим себе ситуацию, когда два потока последовательно много раз пытаются взять одну и ту же блокировку. Как только один из них сможет ее захватить, второй поток не сможет взять блокировку после первого же ее освобождения: возможно в момент отпускания блокировки первым потоком второй поток будет находиться в состоянии ожидания, в таком случае первый поток тут же этим воспользуется и захватит блокировку повторно. Таким образом второй поток не сможет захватить блокировку пока не выйдет из состояния ожидания в нужный момент. Это приводит к тому, что потоки будут выполнять свои действия неравномерно — сначала большую пачку действий выполнит первый потом, потом второй, потом первый вернет себе лидерство и так далее. В идеале же хотелось бы несколько более справедливый алгоритм, который не будет неявным образом отдавать предпочтение тому или иному потоку на протяжении долгого времени.

5 Описание алгоритмов

Желание получить алгоритм, справедливо распределяющий доступ к разделяемому ресурсу между потоками, подводит к достаточно простой идее использования некоторого подобия очереди потоков. Для каждого идентификатора разделяемого ресурса будем хранить в Cassandra две строки: первую будем использовать в качестве подобия очереди (далее «очередь»), во второй будет храниться идентификатор потока, владеющего ресурсом (далее «основная строка»). При добавлении потока в очередь мы будем добавлять новую ячейку в строчку с очередью, при этом имя колонки этой ячейки будет подсчитано следующим образом:

Листинг 5: Определение имени колонки для ячейки в очереди

1. Положить в переменную `currentTime` строковое значение текущего времени в микросекундах
 2. Добавлять к значению `currentTime` ведущие нули до тех пор, пока его длина не станет равной 20
 3. Назначить именем колонки конкатенацию значений `currentTime` и `threadId`
-

В силу свойства порядка хранения ячеек в строке раньше всех в очереди окажется тот поток, который будет добавлен в очередь раньше, в случае равенства времен ближе к вершине очереди окажется поток с лексикографически меньшим идентификатором. При добавлении потока в основную строку именем колонки будем считать просто идентификатор потока.

Описанные алгоритмы реализуют лишь захват блокировки, ее освобождение будет изложено далее. Также все доказательства основываются на том предположении, что потоки будут поступать в очередь с неубывающим временем в качестве префикса имени колонки. Последнее предположение является достаточно грубым в условиях распределенной системы с множеством серверов, так как время на машинах может «разъезжаться» без должного администрирования с точки зрения NTP, Впрочем решение этого вопроса также будет освещено далее в работе.

5.1 Алгоритм обязательной блокировки

Листинг 6: Алгоритм `Cassandra.GetLock(lockId, threadId)`

1. Добавить поток в очередь
 2. Если наш поток - первый в очереди:
 3. Добавить ячейку в основную строку
 4. Если в основной строке есть только одна запись:
 5. Закончить
 6. Иначе:
 7. Удалить ячейку из основной строки
 8. Перейти к шагу 2
 9. Иначе:
 10. Перейти к шагу 2
-

Теорема 1. *В ходе выполнения алгоритма `Cassandra.GetLock` несколькими потоками блокировка не будет взята более чем одним потоком одновременно.*

Теорема 2. *Если в одно и то же время в очередь может поступить не более N потоков, то при одновременном выполнении алгоритма `Cassandra.GetLock` несколькими потоками рано или поздно каждый поток сможет захватить блокировку, обратившись к основной строке не более N раз.*

5.2 Алгоритм мягкой блокировки

Листинг 7: Алгоритм `Cassandra.TryGetLock(lockId, threadId)`

1. Если в основной строке есть хотя бы одна запись
 2. Вернуть `false`
 3. Добавить поток в очередь
 4. Если наш поток - первый в очереди:
 5. Добавить ячейку в основную строку
 6. Если в основной строке есть только одна запись:
 7. Вернуть `true`
 8. Иначе:
 9. Удалить ячейку из основной строки
 10. Перейти к шагу 4
 11. Иначе:
 12. Удалить поток из очереди
 13. Вернуть `false`
-

Утверждение 5.1. *В ходе выполнения алгоритма `Cassandra.TryGetLock` несколькими потоками блокировку сможет взять не более одного потока.*

Утверждение 5.2. *В ходе выполнения алгоритма `Cassandra.TryGetLock` несколькими потоками блокировку хотя бы один поток захватит блокировку.*

Теорема 3. *В ходе выполнения алгоритма `Cassandra.TryGetLock` несколькими потоками блокировку возьмет ровно один поток.*